

Awesome AI Scientist：AI 科学家系统综述

Generated from awesome-ai-scientist-map

Awesome AI Scientist

日期：2026-05-28

摘要

本文将 AI Scientist 生态整理为综述论文格式，综合 31 个系统、产品、基准与数据集条目，分析其分类、能力、自主性、评测方式、风险与未来方向。

关键词：AI 科学家，科研智能体，自动化科学发现，评测基准，综述

目录

1 引言	2
2 语料与综述方法	2
3 AI Scientist 生态分类	3
3.1 端到端 AI 科学家系统	3
3.2 科研工作流智能体	3
3.3 假设生成与研究规划系统	3
3.4 领域科学发现智能体	3
3.5 科学智能体产品套件	4
3.6 深度研究产品	4
3.7 文献综述产品	4
4 历史演化	4
5 科研生命周期中的能力模式	5
6 评测基准综述	5
7 自主性、控制与人类角色	8
8 系统关系与生态结构	8
9 风险、局限与开放问题	8
10 未来方向	8

1 引言

“AI Scientist”已经不再只是会回答科研问题的聊天机器人，而是指一类试图自动化科研生命周期若干环节的系统。最强的主张来自端到端系统：它们尝试生成研究想法、编写代码、运行实验、分析结果并撰写论文。相邻系统则覆盖更窄但同样重要的环节，例如文献综合、假设生成、化学规划、自动化实验室、算法发现、科学编程、可复现性验证和深度研究报告。

本文将该领域视为一个生态，而不是单一排行榜。原因很直接：The AI Scientist、Elicit、PaperBench、Coscientist 与 AlphaEvolve 并不处在同一条能力轴上。它们分别对应科研栈中的不同位置。因此，一篇有用的综述需要同时给出分类法、时间线、自主等级模型和评测图谱，并说明系统、基准、产品、数据集和现实应用之间的关系。

2 语料与综述方法

本文使用 31 个结构化研究记录作为综述语料。记录优先来自论文、官方仓库、产品页面、基准页面和数据集页面。纳入标准是：条目必须自动化或显著增强科学研究工作流，或直接评测这类系统。一般聊天机器人和与科研智能体无直接关系的基础模型不纳入，除非它们作为科研智能体工作流的一部分出现。

语料构成为：端到端 AI 科学家系统 3 个，科研工作流智能体 1 个，假设生成与研究规划系统 1 个，领域科学发现智能体 6 个，科学智能体产品套件 2 个，深度研究产品 1 个，文献综述产品 2 个，评测基准与数据集 15 个。这一分布本身说明该领域尚处在定义能力边界的阶段：评测基准数量几乎与系统构建工作相当，说明社区仍在协商什么样的智能体行为才算“科学进展”。

类别	数量	解释
端到端 AI 科学家系统	3	系统或产品层
科研工作流智能体	1	系统或产品层
假设生成与研究规划系统	1	系统或产品层
领域科学发现智能体	6	系统或产品层
科学智能体产品套件	2	系统或产品层
深度研究产品	1	系统或产品层
文献综述产品	2	系统或产品层
评测基准与数据集	15	评测基础设施

3 AI Scientist 生态分类

AI Scientist 生态可以理解为一个分层结构。最上层是端到端 AI 科学家系统，目标是把选题、实现、实验和论文写作整合为闭环。中间层是领域科学发现智能体，覆盖化学、生物、材料和算法发现等方向。底层和横向层是研究产品与评测基准：前者直接支持人类科研工作，后者衡量智能体是否真的具备可信的研究能力。

3.1 端到端 AI 科学家系统

- **DeepScientist** (2025-09-30, L4: 端到端自主科学家): Local-first autonomous research studio for long-horizon scientific discovery and paper-oriented workflows.
- **The AI Scientist** (2024-08-12, L4: 端到端自主科学家): Autonomous scientist for end-to-end machine learning paper generation.
- **The AI Scientist-v2** (2025-04-07, L4: 端到端自主科学家): Autonomous scientist for open-ended machine-learning discovery via agentic tree search.

3.2 科研工作流智能体

- **Agent Laboratory** (2025-01-08, L3: 半自主研究智能体): Autonomous research assistant

3.3 假设生成与研究规划系统

- **AI Co-Scientist / Co-Scientist** (2025-02-19, L3: 半自主研究智能体): Collaborative co-scientist for scientist-in-the-loop hypothesis generation and research planning.

3.4 领域科学发现智能体

- **A-Lab / GNoME Materials Discovery Lineage** (2023-11, L4: 端到端自主科学家): Autonomous materials discovery stack that combines large-scale learned candidate generation with robotic closed-loop synthesis and characterization.
- **AlphaEvolve** (2025-05-14, L3: 半自主研究智能体): A Gemini-powered evolutionary coding agent for algorithm discovery and system optimization.
- **ChemCrow** (2023-04-11, L2: 工作流智能体): A tool-augmented chemistry assistant that uses GPT-4 plus expert-designed tools to solve reasoning-intensive chemistry tasks.
- **Coscientist** (2023-12-20, L4: 端到端自主科学家): A GPT-4-based autonomous chemistry co-scientist for planning, executing, and optimizing laboratory experiments.
- **Robin** (2025-05-19, L3: 半自主研究智能体): Semi-autonomous scientific discovery system
- **SciAgents** (2024-09-09, L3: 半自主研究智能体): Domain-specific autonomous co-scientist for graph-grounded hypothesis generation in materials science.

3.5 科学智能体产品套件

- **Asta** (2025-08-26, L2: workflow智能体): A science-focused agent ecosystem that combines research assistants, benchmark infrastructure, and developer resources.
- **FutureHouse Platform Agents** (2025-05-01, L2: workflow智能体): Scientific agent platform

3.6 深度研究产品

- **OpenAI Deep Research** (2025-02-02, L2: workflow智能体): An agentic deep-research product for multi-step web research, source analysis, and citation-grounded report generation.

3.7 文献综述产品

- **Consensus** (2021, L1: 任务辅助): AI academic search and evidence-synthesis workspace for scientific research.
- **Elicit** (2021-08-31, L1: 任务辅助): An AI research assistant and literature-review platform focused on paper search, evidence extraction, and synthesis.

这个分类说明，自主性不是一个二元属性。文献综述产品通常处于 L1；深度研究产品和科研产品套件多处于 L2；workflow智能体接近 L3；最强的端到端系统或自动化实验室系统在受限领域内声称达到 L4。本文语料中没有任何条目足以证明开放式 L5 科学自主性。

4 历史演化

现代 AI Scientist 生态从 2023 年的工具增强科学智能体和自动化实验室工作开始，在 2024 年扩展到更广义的 AI Scientist 原型和评测基准，并在 2025-2026 年迅速密集化。时间线显示，领域重心正在从单个概念验证系统转向基准套件和产品化科研助手。

年份	条目数	代表性条目
2021	2	Consensus, Elicit
2023	4	ChemCrow, MAgent-Bench, A-Lab / GNoME Materials Discovery Lineage, Coscientist
2024	7	DiscoveryBench, Sci-Code, The AI Scientist, SciAgents, DSbench, CORE-Bench, MLE-bench

年份	条目数	代表性条目
2025	16	Agent Laboratory, OpenAI Deep Research, AI Co-Scientist / Co-Scientist, BixBench, ResearchBench, PaperBench, The AI Scientist-v2, Deep Research Bench / RetroSearch, FutureHouse Platform Agents, AlphaEvolve, Robin, DeepResearch Bench, AstaBench, Asta, DeepScientist, AInsteinBench
2026	2	MMDeepResearch-Bench, AIRS-Bench

5 科研生命周期中的能力模式

语料中反复出现五类能力模式。第一类是**研究综合**，即检索、筛选、总结并引用文献。第二类是**假设系统**，即生成候选解释、研究灵感或研究计划。第三类是**计算研究智能体**，即为机器学习或数据科学任务编写并运行代码。第四类是**领域发现系统**，即将大语言模型推理与领域工具、实验室自动化或外部模拟器结合。第五类是**评测系统**，即通过任务、评分规则和执行环境把定性的研究行为转化为可比较的结果。

这里最重要的设计张力是广度与验证之间的矛盾。覆盖科研生命周期越广的系统，越难被严格评测。领域系统范围较窄，但有时能够通过真实实验、物理仪器或任务特定指标闭环验证。评测基准处在两者之间：它们提供可比较性，但也可能诱导系统优化基准行为，而不是产生真正的科学发现。

6 评测基准综述

评测层是当前语料中最成熟的部分。它覆盖机器学习实验、论文复现、计算可复现性、数据驱动发现、科学编程、生物信息学、深度研究、多模态报告生成和科学软件维护。这些基准并不测量同一种能力：有的奖励能运行的代码，有的奖励文献支撑的报告，有的测试智能体能否复现论文或维护科学代码库。

基准	发布时间	目标自主性	评测内容
AInsteinBench	2025-12-24	L2-L3: 工作流到半自主研究	scientific repository maintenance, scientific computing code agents, real PR tasks, feature implementation
AIRS-Bench	2026-02-09	L3-L4: 半自主到端到端研究	full ML research lifecycle, idea generation, experiment analysis, iterative refinement
AstaBench	2025-08	L1-L3	scientific research agents, paper finding, scholarly question answering, tool use
BixBench	2025-02-28		bioinformatics, biological data analysis, multi-step dataset exploration, open-ended computational biology reasoning
CORE-Bench	2024-09-17	L2-L3: 工作流到半自主研究	computational reproducibility, research artifact execution, code reproducibility
Deep Research Bench / RetroSearch	2025-05	L2: 工作流智能体	web research agents, frozen-web retrieval, tool use, hallucination
DeepResearch Bench	2025-06	L2: 工作流智能体	deep research agents, citation quality, retrieval accuracy, long-form report quality
DiscoveryBench	2024-07-01	L2-L3: 工作流到半自主研究	data-driven discovery, hypothesis generation, multi-step reasoning, data semantics

基准	发布时间	目标自主性	评测内容
DSBench	2024-09-12		data science, data analysis, data modeling, spreadsheet and Kaggle-style task solving
MLAgentBench	2023-10-05		ML experimentation, code execution, model improvement, long-term planning
MLE-bench	2024-10-09	L2-L3: workflow到半自主研究	ML engineering, Kaggle-style competition performance, agent scaffolds, resource scaling behavior
MMDeepResearch-Bench	2026-01	L2: workflow智能体	multimodal deep research, image-text evidence use, citation grounding, report integrity
PaperBench	2025-04-02		paper-to-code replication, AI research engineering, long-horizon agent execution, autonomous experiment execution
ResearchBench	2025-03-27	L2-L3: workflow到半自主研究	scientific discovery, inspiration-based reasoning, hypothesis generation, literature-grounded ideation
SciCode	2024-07-18		scientific coding, research problem solving, natural-science computation, code synthesis

因此，基准多样性是必要的。PaperBench 和 MLE-bench 更强调科研工程；DiscoveryBench 和 ResearchBench 更强调假设生成；CORE-Bench 和 AInsteinBench 更强调可复现性与科学软件；DeepResearch Bench 和 RetroSearch 更强调来源支撑的报告；BixBench 与 SciCode 则引入领域科

学推理。单一排行榜很难代表整个生态，因为它会隐藏任务定义之间的关键差异。

7 自主性、控制与人类角色

这些记录显示出一致模式：系统越接近端到端自主，越需要明确边界。边界包括基准任务定义、沙箱执行、人工审批、策展数据集、实验室约束、引用要求和事后专家审查。人类科学家仍然是任务定义者、安全审查者、领域验证者和新颖性判断者。

因此，本文语料中的自主阶梯是关系性的。L1 系统支持人工检索和综合；L2 系统在有边界的工作流中串联工具；L3 系统能够提出并迭代假设或实验，但依赖人工关卡；L4 系统在受限领域内执行完整闭环。现有证据不足以把任何系统视为开放式自主科学家。

8 系统关系与生态结构

几个关系贯穿整个语料。AI Scientist 系列推动了端到端机器学习研究闭环，并自然连接到 PaperBench、MLE-bench、MLAgentBench 和 AIRS-Bench。化学与材料系统形成第二条谱系，包含 ChemCrow、Coscientist、A-Lab/GNoME 以及相关领域智能体。Elicit、Consensus、OpenAI Deep Research、Asta 和 FutureHouse agents 则构成产品层：这些系统通常不如研究原型自主，但更可能被真实科研工作者使用。

这种结构很重要，因为一个层次的进展不会自动迁移到另一个层次。一个在科学编程基准上表现好的智能体，不一定是可靠的文献综述者。一个强大的深度研究产品，可能仍缺少实验执行能力。一个在窄化学协议中成功的实验室智能体，也不等于具备开放式理论形成能力。

9 风险、局限与开放问题

语料中反复出现三类风险。第一是**科研诚信风险**：系统可能产生看似合理但缺乏支持的新颖性声明、伪造或弱引用，以及形式完整但证据脆弱的论文。第二是**评测风险**：基准表现可能反映任务特定适配、裁判模型偏差或数据污染，而不是稳定的科研能力。第三是**操作风险**：具备代码执行、网页访问、化学规划或实验室控制能力的智能体，需要比普通搜索工具更强的安全与审计机制。

因此，关键开放问题不只是模型能力问题，还包括来源追踪、基准污染控制、可复现实验日志、人机协同审查设计、领域安全政策，以及如何区分“报告写得好”和“真的做出了发现”。

10 未来方向

未来 AI Scientist 研究应从令人印象深刻的演示转向可控证据。值得推进的方向包括：按科学生命周期阶段做模块化评测；把代码执行与来源支撑报告结合的基准套件；具有专家验证的领域任务；以及能够暴露推理、工具调用、失败和不确定性的系统。该领域也需要保留负结果：失败假设、无效实验和不可复现的智能体输出不应被过滤掉。

11 语料总表

下表列出全部 31 个条目，以满足总数要求并保证综述可审计。

序号	条目	类别	发布时间	自主性	领域
1	A-Lab GNoME Materials Discovery Lineage	/ 领域科学发 现智能体	2023-11	L4: 端到端自 主科学家	材料科学, 无 机化学
2	Agent Labora- tory	科研工作流 智能体	2025-01-08	L3: 半自主研 究智能体	机器学习, general com- putational research
3	AI Co- Scientist / Co-Scientist	假设生成与 研究规划系 统	2025-02-19	L3: 半自主研 究智能体	生物医学, 生 物学, 通用科 学
4	AInsteinBench	评测基准与 数据集	2025-12-24	L2-L3: 工作 流到半自主 研究	scientific computing, quantum chemistry, quantum computing, molecular dynamics
5	AIRS-Bench	评测基准与 数据集	2026-02-09	L3-L4: 半自 主到端到端 研究	machine learning, nat- ural language processing, 数 学, coding
6	AlphaEvolve	领域科学发 现智能体	2025-05-14	L3: 半自主研 究智能体	算法, 数 学, systems optimization, AI 基础设施
7	Asta	科学智能体 产品套件	2025-08-26	L2: workflow智 能体	通用科学

序号	条目	类别	发布时间	自主性	领域
8	AstaBench	评测基准与数据集	2025-08	L1-L3	scientific research, literature understanding, code execution, data analysis
9	BixBench	评测基准与数据集	2025-02-28		生物信息学, computational biology, genomics, transcriptomics
10	ChemCrow	领域科学发现智能体	2023-04-11	L2: 工作流智能体	化学
11	Consensus	文献综述产品	2021	L1: 任务辅助	通用学术研究
12	CORE-Bench	评测基准与数据集	2024-09-17	L2-L3: 工作流到半自主研究	computational reproducibility, computer science, social science, medicine
13	Coscientist	领域科学发现智能体	2023-12-20	L4: 端到端自主科学家	化学
14	Deep Research Bench / RetroSearch	评测基准与数据集	2025-05	L2: 工作流智能体	web research, open-web retrieval, multi-domain factual synthesis, tool-using agents

序号	条目	类别	发布时间	自主性	领域
15	DeepResearch Bench	评测基准与数据集	2025-06	L2: 工作流智能体	deep research, web research, citation-rich report generation, science and technology
16	DeepScientist	端到端 AI 科学家系统	2025-09-30	L4: 端到端自主科学家	机器学习, scientific tasks
17	DiscoveryBench	评测基准与数据集	2024-07-01	L2-L3: 工作流到半自主研究	sociology, 生物学, humanities, economics
18	DSBench	评测基准与数据集	2024-09-12		data science, data analysis, data modeling, tabular reasoning
19	Elicit	文献综述产品	2021-08-31	L1: 任务辅助	通用学术研究, 系统综述
20	FutureHouse Platform Agents	科学智能体产品套件	2025-05-01	L2: 工作流智能体	生物学, 化学, 生物医学
21	MLOAgentBench	评测基准与数据集	2023-10-05		machine learning experimentation, ML engineering, agentic code execution, model improvement

序号	条目	类别	发布时间	自主性	领域
22	MLE-bench	评测基准与数据集	2024-10-09	L2-L3: 工作流到半自主研究	machine learning engineering, Kaggle-style competitions, applied machine learning
23	MMDeepResearch Bench	评测基准与数据集	2026-01	L2: 工作流智能体	多模态深度研究, image-text evidence synthesis, long-form report generation, general research
24	OpenAI Deep Research	深度研究产品	2025-02-02	L2: 工作流智能体	finance, science, policy, engineering
25	PaperBench	评测基准与数据集	2025-04-02		AI research engineering, machine learning paper replication, long-horizon agent execution

序号	条目	类别	发布时间	自主性	领域
26	ResearchBench	评测基准与数据集	2025-03-27	L2-L3: 工作流到半自主研究	general scientific discovery, natural language processing, hypothesis generation, literature-grounded research
27	Robin	领域科学发现智能体	2025-05-19	L3: 半自主研究智能体	生物学, 生物医学
28	SciAgents	领域科学发现智能体	2024-09-09	L3: 半自主研究智能体	材料科学, bioinspired materials
29	SciCode	评测基准与数据集	2024-07-18		scientific coding, 数学, physics, 化学
30	The AI Scientist	端到端 AI 科学家系统	2024-08-12	L4: 端到端自主科学家	机器学习
31	The AI Scientist-v2	端到端 AI 科学家系统	2025-04-07	L4: 端到端自主科学家	机器学习

12 关键来源链接

条目	主要或官方来源
A-Lab / GNoME Materials Discovery Lineage	https://www.nature.com/articles/s41586-023-06734-w
Agent Laboratory	https://arxiv.org/abs/2501.04227

条目	主要或官方来源
AI Co-Scientist / Co-Scientist	https://www.nature.com/articles/s41586-026-10644-y
AInsteinBench	https://arxiv.org/abs/2512.21373
AIRS-Bench	https://arxiv.org/abs/2602.06855
AlphaEvolve	https://arxiv.org/abs/2506.13131
Asta	https://arxiv.org/abs/2510.21652
AstaBench	https://arxiv.org/abs/2510.21652
BixBench	https://arxiv.org/abs/2503.00096
ChemCrow	https://arxiv.org/abs/2304.05376
CORE-Bench	https://arxiv.org/abs/2409.11363
Coscientist	https://www.nature.com/articles/s41586-023-06792-0
Deep Research Bench / RetroSearch	https://arxiv.org/abs/2506.06287
DeepResearch Bench	https://arxiv.org/abs/2506.11763
DeepScientist	https://arxiv.org/abs/2509.26603
DiscoveryBench	https://arxiv.org/abs/2407.01725
DSBench	https://arxiv.org/abs/2409.07703
Elicit	https://elicit.com/

条目	主要或官方来源
MLAgentBench	https://arxiv.org/abs/2310.03302
MLE-bench	https://arxiv.org/abs/2410.07095
MMDeepResearch-Bench	https://arxiv.org/abs/2601.12346
OpenAI Deep Research	https://openai.com/index/introducing-deep-research/
PaperBench	https://arxiv.org/abs/2504.01848
ResearchBench	https://arxiv.org/abs/2503.21248
Robin	https://arxiv.org/abs/2505.13400
SciAgents	https://arxiv.org/abs/2409.05556
SciCode	https://arxiv.org/abs/2407.13168
The AI Scientist	https://arxiv.org/abs/2408.06292
The AI Scientist-v2	https://arxiv.org/abs/2504.08066